



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

UNIDAD DE APRENDIZAJE: BASES DE DATOS

PRÁCTICA 2: MODELO ENTIDAD-RELACIÓN-EXTENDIDO

Ejercicio 3 — Resumen de Artículos Científicos

Profesor: Hurtado Avilés Gabriel

Alumno: Hernandez Barrios Samuel Rodrigo

Tercer Semestre

Grupo: 3CV4

Fecha: 03 Octubre 2026

Artículo 1. Datos sísmicos

Villa Vargas, J. M., Hurtado Avilés, G. y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. AZCATL, 4(6), 28–33.

1. Problema e importancia. México se ubica en el Cinturón de Fuego del Pacífico y es atravesado por cinco placas tectónicas, por lo que cerca del 70 % del territorio está expuesto a riesgo sísmico, incluidas zonas muy pobladas como el Valle de México y Guadalajara. Como los sismos no pueden pronosticarse con certeza, contar con datos confiables de magnitud, profundidad y ubicación es la base para estudiarlos. El Servicio Sismológico Nacional (SSN) publica esa información desde 1900, pero su carácter técnico dificulta que el público general e incluso algunos investigadores la aprovechen. El artículo plantea cómo convertir esos datos en información accesible para cualquier persona interesada.

2. Origen y tratamiento de los datos. La fuente principal es un archivo CSV del SSN con más de 300 000 sismos registrados desde 1900. Como fuentes complementarias se descargan del INEGI dos archivos CSV: uno del Censo de Población y Vivienda 2020 y otro de los Censos Económicos (el texto menciona 2019, mientras que la lista de referencias cita la edición 2024). Un programa en Python revisa los archivos, detecta campos vacíos, coordenadas inconsistentes y formatos incompatibles, descarta los registros inválidos y genera un script SQL con los datos ya validados. Ese script se ejecuta en PostgreSQL para crear la base de datos con estructura de almacén de datos.

3. Modelado de la información. El artículo indica de forma general que la información de sismos, población y economía se organiza como un almacén de datos, pero no detalla el modelo. La captura de Docker de la Figura 6 permite ver cinco tablas: cuatro dimensiones (sismos, zonas, tiempo y economía) y una tabla de hechos sobre el impacto sísmico, que relaciona los eventos con la población potencialmente afectada. Cada sismo se describe por atributos como magnitud, profundidad, fecha y coordenadas, y se vincula con zonas y datos del INEGI mediante su ubicación.

4. Preguntas que responde. El sistema permite filtrar sismos por periodo, magnitud, localidad, profundidad, número de habitantes o producción económica. Con ello responde, por ejemplo, cuántos sismos ocurrieron en un estado y año, cuál fue el de mayor magnitud, qué población vive cerca de los epicentros y hasta dónde llegó el alcance de un evento (mapa de calor). También muestra cómo se distribuyen las magnitudes, la relación entre magnitud y profundidad y los sismos por mes. El ejemplo del artículo es Jalisco en 2017: 47 sismos, uno de magnitud máxima 5.6 y alrededor de 5.5 millones de personas potencialmente afectadas.

5. Limitaciones y trabajo futuro. Los autores no incluyen una sección formal de limitaciones. Reconocen que instalar el sistema puede resultar complicado para quien no domina las herramientas, y lo atienden con Docker Compose, que separa la aplicación en un contenedor de base de datos y otro de servidor web PHP. Como trabajo futuro proponen visualizaciones en 3D, la incorporación de más fuentes oficiales de datos y la integración con plataformas de alerta temprana.

Artículo 2. Consumo de agua en la Ciudad de México

Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A. y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.

1. Problema e importancia. La Ciudad de México enfrenta una crisis hídrica por la sobreexplotación del acuífero, las fugas en la red y el crecimiento poblacional. Aunque SACMEX publica datos abiertos de consumo, están en formatos poco accesibles y sin herramientas de consulta, lo que limita su uso para tomar decisiones con evidencia. El trabajo busca convertir esos datos dispersos en un repositorio consultable que ciudadanos, servidores públicos, investigadores y periodistas puedan filtrar y visualizar por territorio.

2. Origen y tratamiento de los datos. El recurso principal es el CSV «Consumo Agua (1er Semestre 2019)» del portal de datos abiertos de la Ciudad de México: 71 102 registros que cubren solo tres bimestres de un año, sin versiones ni actualizaciones desde 2023. La serie climática proviene de OpenMeteo y el mapa base de OpenStreetMap. El proceso ETL tiene cuatro fases: extracción de los CSV, validación y limpieza, carga a tablas temporales (staging) con población de dimensiones, y llenado de las tablas de hechos. Solo se descartaron 216 registros (0.30 %) cuyas etiquetas de colonia y alcaldía eran «NA», por lo que se cargaron 70 886. Además, un mapeo declarativo R2RML republica el almacén como grafo de conocimiento RDF.

3. Modelado de la información. Se usa un esquema en estrella con dos tablas de hechos, fact_consumo_agua (una manzana en un periodo de facturación) y fact_clima, y tres dimensiones compartidas: dim_tiempo (fecha, año y bimestre), dim_ubicacion (alcaldía, colonia y coordenadas) y dim_indice_des (nivel de desarrollo: alto, medio, bajo y popular). El almacén contiene 1 553 ubicaciones y 181 registros de tiempo, correspondientes a las observaciones diarias del clima. En el grafo, cada fila de hechos se vuelve una observación del RDF Data Cube y cada colonia, un elemento geográfico representado por el centroide de sus lecturas.

4. Preguntas que responde. Permite consultar el consumo por año, bimestre, alcaldía y colonia, y obtener totales y promedios. Muestra qué alcaldías consumen más (Cuauhtémoc y Miguel Hidalgo encabezan la lista), cómo se compara el consumo según el índice de desarrollo y qué colonias se alejan más del comportamiento de su alcaldía, mediante un puntaje de atipicidad. Gracias al grafo también responde cuáles colonias están a menos de 1.5 km de una zona dada y cuánto consumen. Los autores advierten que el consumo total no equivale a consumo per cápita.

5. Limitaciones y trabajo futuro. Reconocen cuatro límites: los datos abarcan solo tres bimestres, de modo que no se puede estimar la relación con el clima; el módulo de atípicos se evaluó con perturbaciones sintéticas y no detecta fugas reales; las colonias se representan con puntos y no con polígonos, por lo que la «vecindad» es solo cercanía; y la asociación entre desarrollo y consumo es descriptiva. Proponen un almacén de tripletas persistente con punto de acceso SPARQL público, polígonos oficiales, alinear los identificadores con autoridades externas, reevaluar el detector con datos etiquetados y aplicar el método a otros dominios urbanos.

Artículo 3. Obra pública municipal

González Casiano, U., Maldonado Mejía, M. T. y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En Advances in Computer Science Applications and Research. Springer.

1. Problema e importancia. Los departamentos municipales de obras manejan contratistas, presupuestos, supervisores, fotografías e informes, pero casi siempre con archivos dispersos, hojas de cálculo o sistemas transaccionales aislados. Eso impide el análisis histórico, la detección temprana de retrasos y la participación ciudadana informada, lo cual debilita la transparencia. El artículo propone un almacén dimensional que sirva de base para vigilar las obras de forma auditable y abierta a la ciudadanía.

2. Origen y tratamiento de los datos. Todos los datos son sintéticos, porque por privacidad no pueden publicarse registros municipales reales. Se genera con semilla fija una población para Temascaltepec: 1 247 obras, 55 comunidades y un presupuesto acumulado de 127.4 millones de pesos. Los datos estructurados y las evidencias (fotos en JPG/PNG y documentos PDF) entran por formularios web hacia una API REST en Flask; las evidencias se guardan en Cloudflare R2 y sus metadatos en el almacén. No hay ETL externo: triggers de PostgreSQL alimentan las dimensiones (con versionado) y registran eventos en la tabla de hechos. Las coordenadas de cada comunidad se toman de OpenStreetMap.

3. Modelado de la información. Es un esquema en estrella con diez dimensiones y dos tablas de hechos. Cinco dimensiones son de tipo 2 y conservan historial (obra, región, empresa, personal y presupuesto); tres son de tipo 1 (fuente de financiamiento, ciudadano y propuesta) y dos de tipo 0 (tiempo y tipo de evento). Un hecho registra un evento de auditoría (17 tipos, como cambio de presupuesto, reporte de avance o voto) y el otro es una instantánea mensual por obra, con presupuesto, costo acumulado, avance físico, avance financiero y bandera de retraso. Seis vistas analíticas se construyen sobre estas tablas.

4. Preguntas que responde. Identifica qué obras están retrasadas y por cuántos días, y qué eventos merecen alerta (montos altos, obras canceladas, cambios de presupuesto). Gracias al versionado puede reconstruir qué presupuesto o contratista tenía una obra en una fecha dada. También informa la ejecución presupuestal por fuente de financiamiento, la participación ciudadana por región y las obras con posibles anomalías, como un gasto alto con avance físico bajo. Un visor geoespacial muestra las obras por estado (completada, en proceso o retrasada).

5. Limitaciones y trabajo futuro. Los autores señalan que no hay un despliegue dinámico alojado, que el voto simple puede subrepresentar a las minorías, que la calidad depende de la captura de los supervisores, que todos los resultados vienen de datos sintéticos, que el almacenamiento de objetos no se consulta analíticamente, que los endpoints del mapa leen el esquema operativo y no el almacén, y que el control de acceso es ligero. Su detector de anomalías alcanza una precisión de 0.46 y una exhaustividad de 0.35, y no supera a Isolation Forest. Como trabajo futuro plantean evolucionar hacia un lakehouse (Iceberg o Parquet sobre R2), clasificar el avance con visión por computadora, publicar el esquema como vocabulario OWL y compatible con OC4IDS, votación cuadrática, modelos de series de tiempo, un criterio de costos por tipo de obra y validación en más municipios.

Referencias

- González Casiano, U., Maldonado Mejía, M. T. y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.
- Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A. y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.
- Villa Vargas, J. M., Hurtado Avilés, G. y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación de la Ciencia, la Ingeniería y la Innovación*, 4(6), 28–33. <https://doi.org/10.24275/AZC2026E1004>